Incident Report

• 장애 요약

API 서비스에서 Error Rate 급증과 p95 Latency가 증가하면서 설정된 SLO 기준을 초과하였습니다.
Prometheus Alert Rule에 의해 Alert 상태가 Inactive → Pending → Firing으로 전환되며 장애가 감지되었습니다.
api 요청 중단 후, 정상 범위로 회복되면서 장애가 종료되었습니다.

• 영향 범위

이번 장애는 테스트 환경에서 의도적으로 발생시킨 장애로 다른 서비스에는 영향을 주지 않았습니다.

• 타임라인

시각	단계	내용
19 : 49 : 01	장애 발생	`for i in {1..60}; do curl -s http://localhost:8080/error > /dev/null; sleep 1; done` `for i in {1..200}; do curl -s "http://localhost:8080/delay?ms=1000" > /dev/null; done`
19 : 50 : 00	대시보드 상태	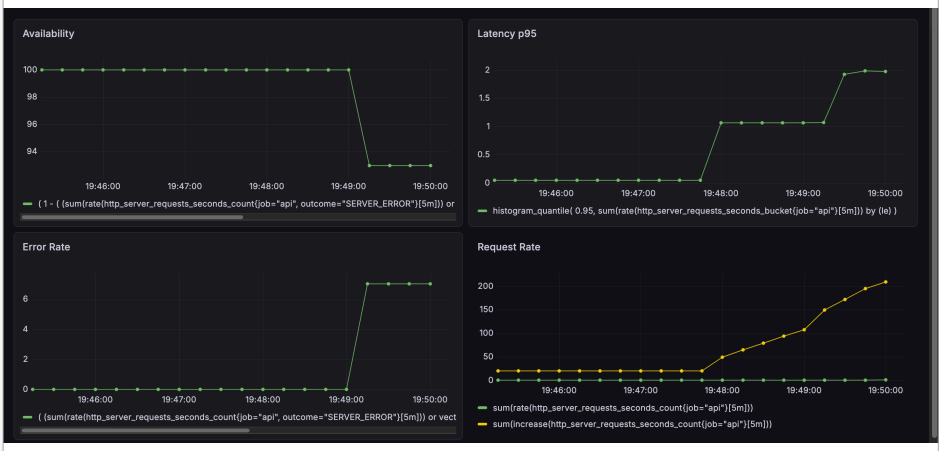
19 : 50 : 30	Alert 발생	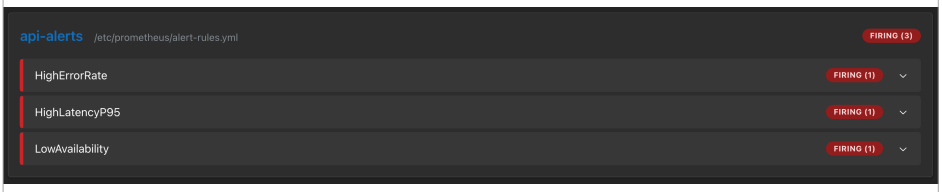
19 : 50 : 33	복구 확인	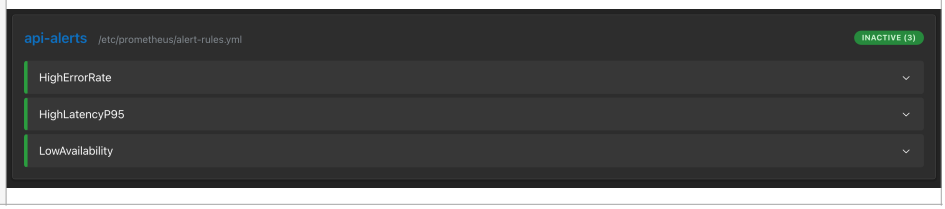

• Root Cause

SLO가 위반되며 HighErrorRate, HighLatencyP95, LowAvailability에서 alert가 발생되었습니다.
SLO가 위반된 이유는 “/error’, “/delay” 엔드포인트를 대량 호출했기 때문입니다.

즉, 장애의 원인은 API 서버에 오류 응답을 발생시키는 요청과 응답 지연을 유발하는 요청이 동시에 증가해서 발생한 장애입니다.

• 재발 방지 대책

1. 오류 발생 원인 분석 및 로그 모니터링 강화
   에러가 발생한 요청을 원인을 빠르게 파악할 수 있도록 로그 수집 및 분석 체계를 강화합니다.

2. Rate Limiting
   문제가 발생한 엔드포엔트에서 Rate Limiting을 적용해 대량 호출을 방지합니다.

3. 트래픽 증가 추이에 따라 SLO 목표값으로 재검토합니다.
   기존 p95 Latency를 p99 Latency로 변경하고,
   Availabillity 목표를 99.9%로 설정한다면 기존보다 빠르게 대응할 수 있을 것입니다.

4. 알람 감지 시간 감축
   최근 5분 동안 관측하며, 기존 30초 동안 pending 상태가 이어질 경우 firing 상태로 변환되었습니다.
   관측 시간을 줄이고, pending 상태가 30초가 아닌 10초 동안 이어질 경우 firing 상태로 변환되면
   기존보다 빠르게 대응할 수 있을 것입니다.